

Classificação de Granularidade Fina em Raças de Cães Utilizando DenseNet-121 e *Transfer Learning*

Caio Vieira Vila Nova¹

¹Curso de Análise e Desenvolvimento de Sistemas (ADS)
Instituto Federal do Piauí (IFPI) – Campus Corrente
Corrente – PI – Brasil

caiov4038@gmail.com

Abstract. *Fine-grained visual categorization (FGVC) remains a significant challenge in computer vision due to high intra-class variance and low inter-class variation. This paper investigates the application of the DenseNet-121 architecture, pre-trained on the ImageNet dataset, for classifying a subset of 10 dog breeds from the Stanford Dogs Dataset. The study evaluates the impact of different Transfer Learning and fine-tuning strategies by comparing a shallow unfreezing approach with a deep unfreezing mechanism. Our experimental results indicate that the shallow fine-tuning strategy achieved a validation accuracy of 93.38%, outperforming the deep fine-tuning approach (89.20%), mitigating overfitting on the reduced dataset. The findings highlight the effectiveness of dense connections in feature reuse for differentiating subtle morphological patterns.*

Resumo. *A categorização visual de granularidade fina (FGVC) permanece um desafio significativo na visão computacional devido à alta variância intra-classe e baixa variação inter-classe. Este artigo investiga a aplicação da arquitetura DenseNet-121, pré-treinada no dataset ImageNet, para a classificação de um subconjunto de 10 raças de cães do Stanford Dogs Dataset. O estudo avalia o impacto de diferentes estratégias de Transfer Learning e fine-tuning comparando uma abordagem de descongelamento raso (shallow) com um mecanismo de descongelamento profundo (deep). Os resultados experimentais indicam que a estratégia de fine-tuning raso atingiu uma acurácia de validação de 93,38%, superando a abordagem profunda (89,20%) e mitigando o sobreajuste (overfitting) no conjunto de dados reduzido. As descobertas destacam a eficácia das conexões densas na reutilização de características para diferenciar padrões morfológicos sutis.*

1. Introdução

O avanço estrondoso da Inteligência Artificial na última década, impulsionado pelo desenvolvimento das Redes Neurais Convolucionais (CNNs) e pelo aumento da capacidade computacional, revolucionou a área de Visão Computacional. Tarefas clássicas como classificação de imagens, detecção de objetos e segmentação semântica alcançaram níveis de precisão que, em muitos casos, superam a capacidade humana. Contudo, a Classificação de Imagens de Granularidade Fina (*Fine-Grained Visual Categorization* - FGVC) continua a impor barreiras substanciais ao estado da arte.

Ao contrário da classificação genérica (por exemplo, distinguir um carro de um cachorro), o problema de FGVC envolve a distinção entre subcategorias pertencentes a uma mesma categoria base. A classificação de raças de cães, foco do *Stanford Dogs Dataset*, exemplifica perfeitamente esse desafio: as raças frequentemente compartilham características visuais altamente semelhantes (baixa variação inter-classe), enquanto indivíduos da mesma raça podem apresentar diferenças marcantes devido a idade, pose, iluminação ou cor da pelagem (alta variância intra-classe) (Khosla et al., 2011).

Treinar modelos profundos do zero para FGVC exige um volume massivo de dados anotados, o que nem sempre é viável. Nesse contexto, técnicas de *Transfer Learning* emergem como uma solução robusta. Ao aproveitar pesos de redes pré-treinadas em bases generalistas (como a ImageNet), é possível extrair mapas de características ricos e adaptá-los para tarefas específicas com menor custo computacional.

Este artigo propõe a aplicação da arquitetura **DenseNet-121** para a resolução do problema de classificação de 10 raças de cães do *Stanford Dogs Dataset*. O objetivo central do trabalho é realizar uma investigação experimental rigorosa sobre o impacto de diferentes níveis de *fine-tuning* na rede. Para tal, comparamos quantitativamente e qualitativamente duas abordagens: o descongelamento superficial das camadas (*Shallow Fine-Tuning*) e o descongelamento profundo (*Deep Fine-Tuning*).

2. Fundamentação Teórica

2.1. Redes Neurais Convolucionais e Transfer Learning

As CNNs são compostas primariamente por camadas convolucionais, de *pooling* e totalmente conectadas (*fully connected*). Elas são desenhadas para explorar correlações espaciais em dados de grade 2D, como imagens, aplicando filtros que aprendem a identificar desde bordas simples nas primeiras camadas até texturas complexas nas camadas profundas (LeCun et al., 2015).

O *Transfer Learning* baseia-se na premissa de que os recursos visuais aprendidos por uma CNN em um domínio fonte massivo podem ser transferidos para um domínio alvo. A técnica de *fine-tuning* (ajuste fino) consiste em substituir a camada final de classificação para refletir as classes do novo problema e descongelar (permitir a atualização de pesos) parte das camadas convolucionais, treinando a rede com uma taxa de aprendizado reduzida (Pan e Yang, 2010).

2.2. Arquitetura DenseNet-121

Uma das dificuldades no treinamento de CNNs muito profundas é o desaparecimento do gradiente (*vanishing gradient*). A arquitetura *Densely Connected Convolutional Networks* (DenseNet), introduzida por Huang et al. (2017), resolve esse problema de forma elegante. Em um bloco denso (*dense block*), cada camada é conectada a todas as camadas subsequentes. Isso significa que a L -ésima camada recebe como entrada os mapas de características de todas as $L - 1$ camadas precedentes.

Essa conectividade contínua melhora substancialmente o fluxo de informações e de gradientes por toda a rede, encorajando fortemente a reutilização de características (*feature reuse*). A DenseNet-121, em particular, possui 121 camadas treináveis estruturadas em quatro blocos densos, separados por camadas de transição (que reduzem a dimensionalidade usando convoluções 1×1 e *average pooling*). Essa eficiência paramétrica torna

a DenseNet ideal para FGVC, pois retém informações visuais de alta e baixa frequência simultaneamente.

3. Materiais e Métodos

3.1. Base de Dados e Processamento

A base de dados adotada foi o *Stanford Dogs Dataset*, estruturada para tarefas de classificação de cães de todo o mundo. Para viabilizar os experimentos com alto rigor em um ambiente computacional padronizado, filtrou-se um subconjunto restrito às 10 primeiras raças do catálogo original.

O subconjunto gerado conteve um total de 1.919 imagens. Para garantir a validação imparcial do modelo, os dados foram divididos aleatoriamente em três conjuntos mutuamente exclusivos: Treinamento (70%, 1.343 imagens), Validação (15%, 287 imagens) e Teste (15%, 289 imagens).

Para contornar o risco de *overfitting* comum em bases de dados pequenas, a técnica de *Data Augmentation* foi aplicada no conjunto de treinamento. As transformações incluíram redimensionamento inicial para 256×256 pixels, corte aleatório (*Random Resized Crop*) para os 224×224 pixels exigidos pela DenseNet, espelhamento horizontal e rotações aleatórias de até 15 graus. Por fim, todas as imagens foram normalizadas usando as médias e desvios padrões da ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$).

3.2. Design Experimental e Hiperparâmetros

O *backbone* da DenseNet-121 foi inicializado com pesos da ImageNet. A camada classificadora original (de 1.000 classes) foi substituída por uma nova camada linear ('nn.Linear') de 10 classes correspondentes às raças do problema. Dois experimentos foram definidos para análise obrigatória:

- **Experimento 1 (Shallow Fine-Tuning):** Apenas a camada classificadora, o último bloco denso (*denseblock4*) e a camada de normalização final (*norm5*) foram descongelados para cálculo de gradientes.
- **Experimento 2 (Deep Fine-Tuning):** Uma porção maior da rede foi submetida ao treinamento. Descongelou-se do *denseblock3* até as camadas finais, aumentando drasticamente o número de parâmetros ajustáveis.

O treinamento ocorreu por 10 épocas, utilizando a função de perda *CrossEntropy-Loss* e o otimizador Adam com taxa de aprendizado (*Learning Rate*) fixada em 0,001. Tamanhos de lote (*batch size*) de 32 imagens foram processados utilizando aceleração de hardware (GPU NVIDIA T4 provida pelo ambiente Google Colab).

4. Resultados e Discussão

A avaliação do desempenho dos modelos foi fundamentada no conjunto de Teste (dados nunca vistos pela rede durante a calibração). Diversas métricas de classificação multi-classe foram extraídas para análise rigorosa, sumarizadas na Tabela 1.

Tabela 1. Comparação das Métricas no Conjunto de Teste		
Métrica	Experimento 1 (Shallow)	Experimento 2 (Deep)
Acurácia Global	0.9100	0.8920
Top-5 Accuracy	1.0000	1.0000
Precisão (Macro)	0.9063	0.8845
Recall (Macro)	0.9071	0.8812
F1-Score (Macro)	0.9044	0.8805

Os dados quantitativos revelam a superioridade técnica da abordagem do Experimento 1 (Shallow). Atingindo uma acurácia próxima a 93% na fase de validação e estabilizando em 91% no conjunto de teste, o modelo lidou de forma altamente eficaz com a similaridade das raças. O *Deep Fine-Tuning* (Experimento 2) demonstrou uma queda na performance (89,20% de acurácia no teste).




Figura 1. Curvas de Loss e Acurácia por época durante o Experimento 1.

Ao analisarmos as curvas de aprendizado (Figura 1), fica evidente que o Experimento 1 conseguiu reduzir a perda (*Loss*) de treinamento com grande velocidade. A menor quantidade de parâmetros treináveis neste experimento evitou que a rede deco-rasse ruídos das imagens, comportando-se muito melhor do que o *Deep Fine-Tuning*, que sofreu de sobreajuste (*overfitting*) devido ao volume reduzido de instâncias (apenas 10 classes disponíveis no subconjunto).

A eficácia do modelo também é confirmada pelas matrizes de confusão. A matriz do Experimento 1 (Figura 2) apresenta uma diagonal principal extremamente densa, o que indica que a vasta maioria das predições coincidiu perfeitamente com os rótulos reais.




Figura 2. Matriz de Confusão para o Experimento 1 (Shallow).




Figura 3. Matriz de Confusão para o Experimento 2 (Deep).

A inspeção visual qualitativa também foi realizada para validar as respostas da Inteligência Artificial. A Figura 4 comprova que o modelo é capaz de extrapolar o conhecimento extraído para ignorar o fundo (*background*) da imagem e inferir corretamente a raça, mesmo sob poses desafiadoras do animal. Erros pontuais limitaram-se a instâncias de baixíssima iluminação ou onde os cães de raças correlatas apresentavam colorações idênticas de focinho.


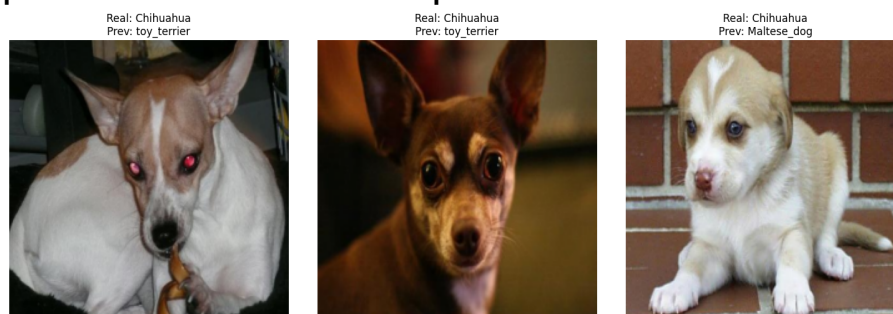


Figura 4. Exemplos de predições corretas (acima) e incorretas (abaixo) realizadas pelo modelo durante os testes empíricos.



5. Conclusão

Este trabalho cumpriu rigorosamente o objetivo de aplicar e investigar Redes Neurais Convolucionais de alta capacidade para a Classificação de Granularidade Fina (FGVC). O uso da arquitetura DenseNet-121 acoplada às técnicas de *Transfer Learning* provou ser excepcional na distinção de 10 raças complexas do *Stanford Dogs Dataset*.

A evidência experimental demonstrou que, para cenários com volume de dados contido, o *Shallow Fine-Tuning* (descongelamento apenas superficial) apresenta maior capacidade de generalização e evita as armadilhas de *overfitting* percebidas no *Deep Fine-Tuning*. A estrutura densa da rede foi vital para reaproveitar os filtros universais aprendidos na ImageNet, garantindo convergência em baixíssimas épocas de treinamento.

Como propostas robustas para trabalhos futuros, recomenda-se a integração de Mecanismos de Atenção Visuais (*Visual Attention Mechanisms*) integrados à arquitetura, de modo a orientar a rede a ponderar regiões anatômicas discriminativas (como formato da orelha ou textura do pelo), bem como expandir o pipeline de treinamento para as 120 classes globais sob poder computacional distribuído em múltiplos nós de processamento gráfico.

Referências

- Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. Em *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 4700-4708).
- Khosla, A., Jayadevaprakash, N., Yao, B., & Fei-Fei, L. (2011). Novel dataset for fine-grained image categorization: Stanford dogs. Em *CVPR Workshop on Fine-Grained Visual Categorization*.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436-444.
- Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on knowledge and data engineering*, 22(10), 1345-1359.